Large-scale Testing of Global Optimization Methods with Black-box Adversarial Attacks

Wojciech Zarzecki, Jarosław Arabas

Politechnika Warszawska | Instytut Informatyki

Plan prezentacji

1. **Globalna optymalizacja: wstęp**
   GEN, DE i reszta
2. **Jak dotychczas testowano dziedzinę**
   Od funkcji z lat 70. do nowoczesnych zestawów
3. **Ataki adwersarialne: co i dlaczego**
   Gdy mały szum zmienia decyzję klasyfikatora
4. **Atak jako problem optymalizacji**
   Formalizacja i diagnoza krajobrazu
5. **Benchmarkowanie optymalizatorów na atakach**
   Wyniki na CIFAR-10 i ImageNet
6. **Wnioski i dalsze kierunki**

Dlaczego ten temat?

Dwie społeczności, które rzadko się spotykają

Globalna optymalizacja

- benchmarki = garstka funkcji analitycznych z lat 70-80.
- zazwyczaj niskowymiarowe (< 100 wymiarów)
- ryzyko: metody przeuczają się na zestawach

Nowoczesne uczenie maszynowe

- modele z milionami / miliardami parametrów
- nowe problemy: odporność adwersarialna, bezpieczeństwo
- proces uczenia modelu to optymalizacja funkcji straty

Cel: ataki adwersarialne jako realistyczny, wysokowymiarowy benchmark dla globalnych optymalizatorów.

Czym jest globalna optymalizacja?

Znajdź najlepszy punkt, a nie tylko lokalnie dobry

Problem

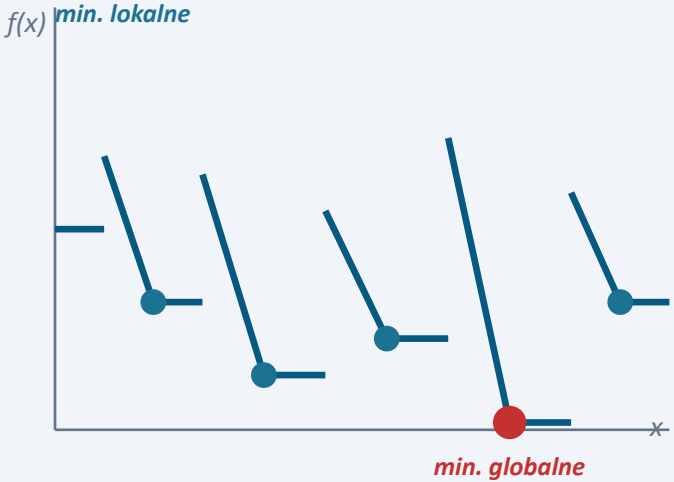
`min f(x)  dla x w ograniczonej dziedzinie`

Wyzwanie

f może być niewypukła, zaszumiona i droga w obliczaniu. Wiele minimów lokalnych.

Tryb czarnej skrzynki

Brak gradientu, tylko ewaluacje funkcji. Próbujesz wejście, widzisz wyjście.



Krajobraz wielomodalny

Mutacyjny algorytm ewolucyjny (GEN)

Klasyczna receptura: selekcja i mutacja

algorytm ***mutacyjny ewolucyjny***
inicjuj $P^0 \leftarrow \{P^0_{1,} P^0_2 \ldots P^0_\mu\}$
$t \leftarrow 0$
$H \leftarrow P^0$
while *! stop*
    for $(i \in 1:\mu)$
        $O^t_i \leftarrow mutation(select(P^t))$
        $P^{t+1}_i \leftarrow O^t_i$
    $H \leftarrow H \cup P^t$
    $t \leftarrow t+1$

Mutacyjny algorytm ewolucyjny (GEN)

Klasyczna receptura: selekcja i mutacja

- *algorytm* ***mutacyjny ewolucyjny***

  inicjuj $P^0 \leftarrow \{P_1^0, P_2^0 \dots P_\mu^0\}$

  $t \leftarrow 0$

  $H \leftarrow P^0$

  while *! stop*

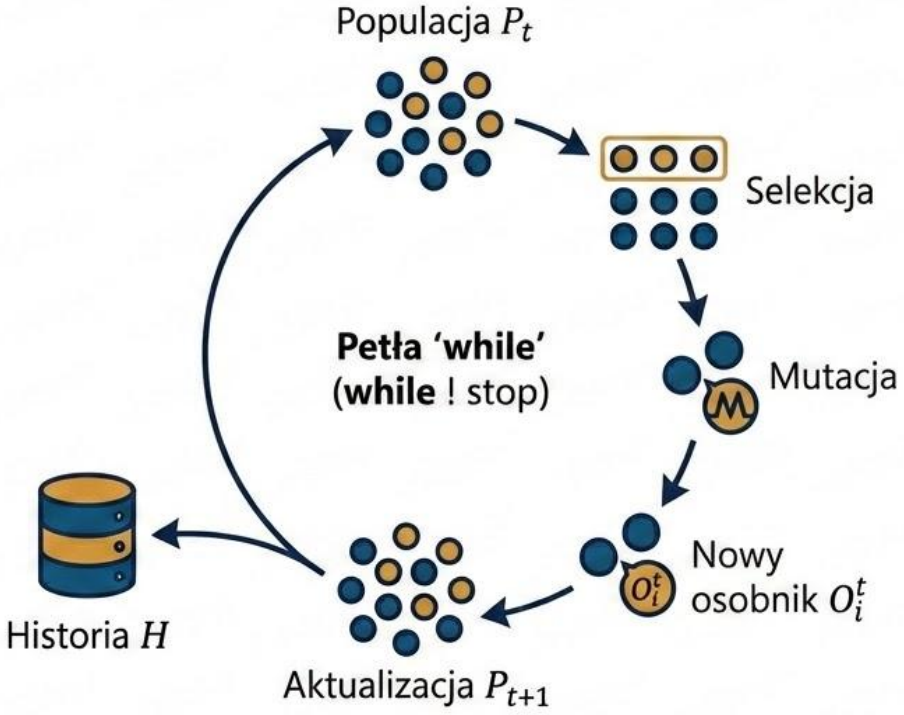
  for $(i \in 1:\mu)$

  $O_i^t \leftarrow mutation(select(P^t))$

  $P_i^{t+1} \leftarrow O_i^t$

  $H \leftarrow H \cup P^t$

  $t \leftarrow t+1$



Ewolucja Różnicowa (DE)

Mutacja napędzana różnicami w populacji

Główna idea

Mutuj wektor docelowy używając różnicy między dwoma innymi osobnikami populacji.

DE / rand / 1:

```
v = x_r1  +  F * ( x_r2  -  x_r3 )
```

r1, r2, r3 to trzy różne losowe osobniki populacji; F to współczynnik skali (zwykle 0.5)

Mutacja

Generuj wektor dawcy v ze wzoru powyżej

Krzyżowanie

Mieszaj v z rodzicem x, aby uzyskać próbkę u

Selekcja

Zachowaj u tylko jeśli f(u) jest lepsze od f(x)

Pozostałe testowane algorytmy

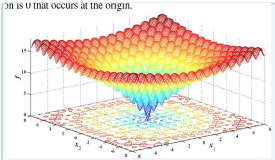
Krótka lista, aby późniejsze wykresy były zrozumiałe

Metoda	Rodzina	Opis w jednym zdaniu
JADE	*DE*	Wariant DE z adaptacyjnym współczynnikiem skali F i wskaźnikiem krzyżowania CR
SADE	*DE*	Samo-adaptacyjne DE: automatycznie wybiera spośród wielu strategii mutacji
SHADE	*DE*	Adaptacyjne DE oparte na historii sukcesów: pamięta dobre wartości parametrów
GWO	*Rój*	Optymalizator Szarego Wilka: modeluje polowanie wilków alfa, beta i delta
INFO	*Śred. ważona*	Używa ważonych średnich wektorów; zachowuje się jak przeszukiwanie lokalne

Wszystkie uruchomione z domyślnymi hiperparametrami z biblioteki mealpy, pop=500, iter=500.

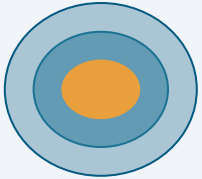
Jak testowano dziedzinę: klasyczne funkcje

Analityczne problemy zabawkowe z lat 70. do 90.



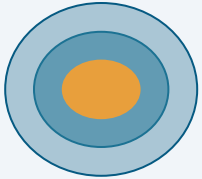
Ackley

wiele małych studzien, jedno głębokie centrum



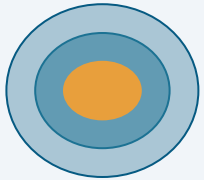
Rastrigin

ekstremalnie nierówny krajobraz kosinusowy



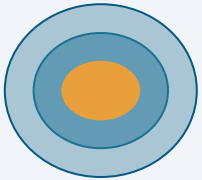
Rosenbrock

wąska zakrzywiona dolina, trudna do nawigacji



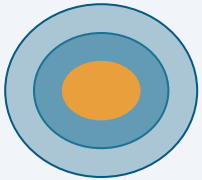
Griewank

pułapki iloczynu cosinusów



Schwefel

min. globalne daleko od centrum, wiele przynęt



Schaffer

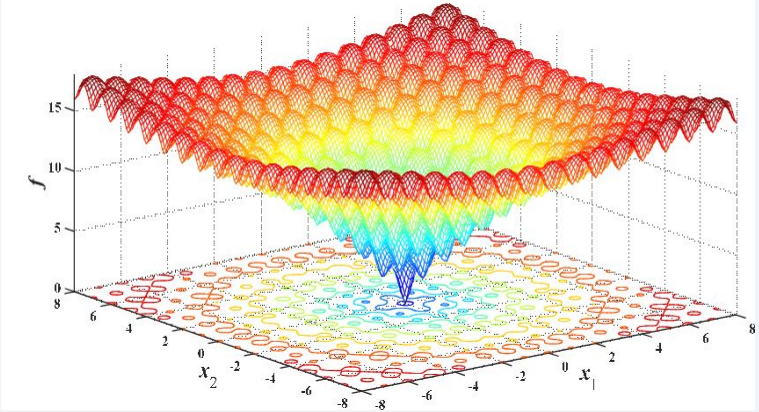
oscylujący pierścień minimów

Stosowane do dziś, ponad 30 lat później. Łatwe do analizy, ale dalekie od rzeczywistych problemów ML.

Jak testowano dziedzinę: klasyczne funkcje

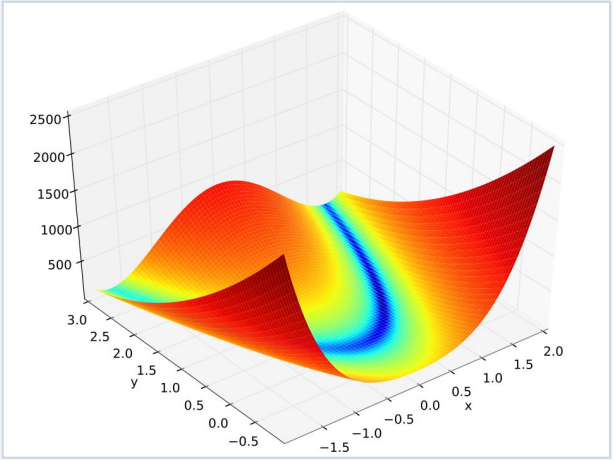
Analityczne problemy zabawkowe z lat 70. do 90.

Ackley



wiele małych studzien, jedno głębokie centrum

Rosenbrock



wąska zakrzywiona dolina, trudna do nawigacji

Stosowane do dziś, ponad 30 lat później. Łatwe do analizy, ale dalekie od rzeczywistych problemów ML.

Zestawy benchmarkowe w skrócie

Wymiarowość nigdy nie dotrzymała kroku nowoczesnemu ML

Rok	Zestaw	Maks. wymiary	Charakter
1978	Dixon-Szegö	`~10`	Pierwszy standaryzowany zestaw dla globalnej optymalizacji
2005+	CEC	`10, 30, 50, do 100`	Styl konkursowy, z kodem do uruchomienia
2009+	COCO / BBOB	`do 40`	Standaryzowana platforma, odtwarzalne eksperymenty
~2015	BBComp	`do 64`	Po stronie serwera, ogranicza zapytania, unika przeuczenia
2012+	CEC dużej skali	`do 1000`	Syntetyczne, nie wywodzące się z rzeczywistych zadań
2019	COCO dużej skali	`do 640`	Syntetyczne skalowanie
2020	CEC real-world	`do 7`	Rzeczywiste problemy inżynierskie, ale małe
2020	NeurIPS BBO	`~dziesiątki`	Dostrajanie hiperparametrów ML

Tymczasem klasyfikatory ImageNet operują w ~150 000 wymiarach pikselowych.

Czym jest atak adwersarialny?

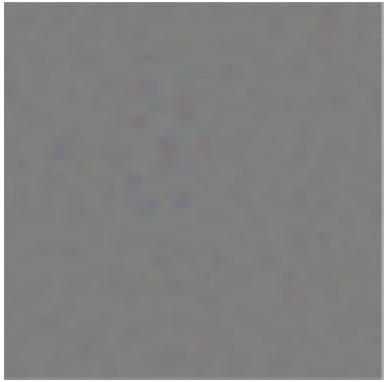
Małe, często niewidoczne zaburzenie zmieniające decyzję modelu



koń

oryginalny obraz

+



+ szum

małe zaburzenie

=



kot ?!

klasyfikator oszukany

Znajdź zaburzenie delta zmieniające predykcję modelu, a zarazem na tyle małe, by pozostać niewidocznym.

Dlaczego ataki adwersarialne są ważne?

Dwie strony tego samego medalu

Zagrożenia dla systemów AI

- Znaki stopu odczytywane jako ograniczenia prędkości
- Błędne diagnozy systemów obrazowania medycznego
- Omijanie rozpoznawania twarzy specjalnymi okularami
- Klasyfikatory złośliwego oprogramowania pokonane małymi zmianami

Zastosowania niegroźne

- Znakowanie sieci neuronowych za pomocą backdoorów
- Ochrona obrazów przed złośliwą edycją dyfuzyjną
- Ochrona prywatności przed scrapingiem twarzy
- Testowanie odporności i oceny bezpieczeństwa

Ataki: biała skrzynka vs czarna skrzynka

Ile napastnik wie o modelu?

Biała skrzynka

- Pełny dostęp do wag modelu
- Obliczanie gradientów straty względem wejścia
- Klasyczne: FGSM, PGD, C&W

Silne, ale nierealistyczne w praktyce

Czarna skrzynka

- Tylko dostęp wejście-wyjście do modelu
- W najlepszym wypadku: prawdopodobieństwa dla każdej klasy
- Brak gradientu, tylko zapytania
- Nasze podejście: traktować jako optymalizację

Realistyczne, dlatego to optymalizujemy

Formalizacja ataku

Problem minimalizacji z ograniczeniami

$$\mathcal{L}(\boldsymbol{\delta}) = -\log p_{c(\mathbf{x})}(\mathbf{x}+\boldsymbol{\delta}) - \alpha\|\boldsymbol{\delta}\|_2^2 \quad , \quad [-\varepsilon, \varepsilon]^n$$

Składnik NLL

Zmniejsz prawdopodobieństwo prawdziwej klasy. Zmiana etykiety to obniżenie tej wartości.

Regularyzacja

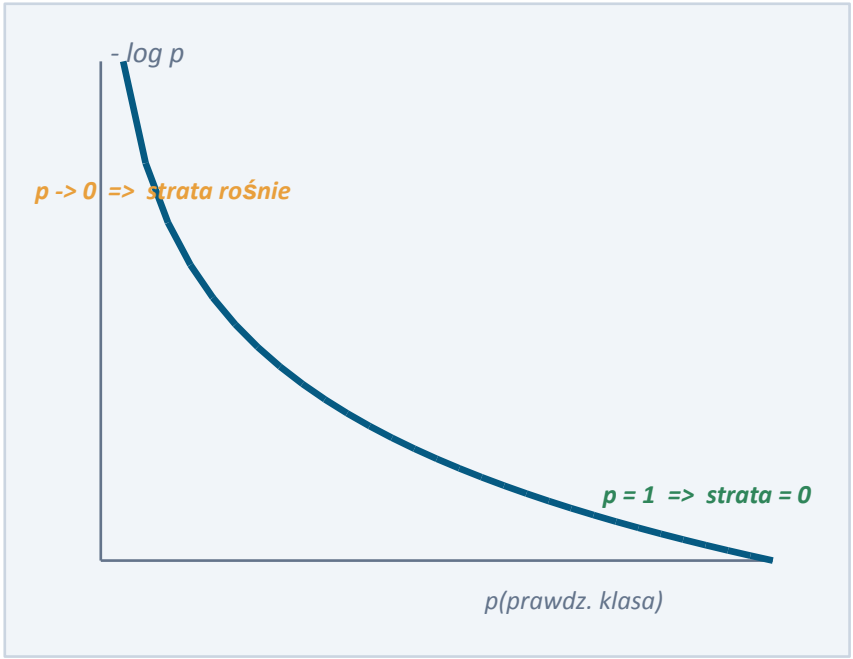
Norma L2 do kwadratu utrzymuje zaburzenie małe. Alfa kontroluje kompromis.

Ograniczenie

delta należy do [-epsilon, epsilon]^n. Wartości pikseli obcinane do [0, 1].

Intuicja: dlaczego ujemne log-prawdopodobieństwo (NLL)?

Karze pewność co do prawdziwej klasy, nie tylko błędność



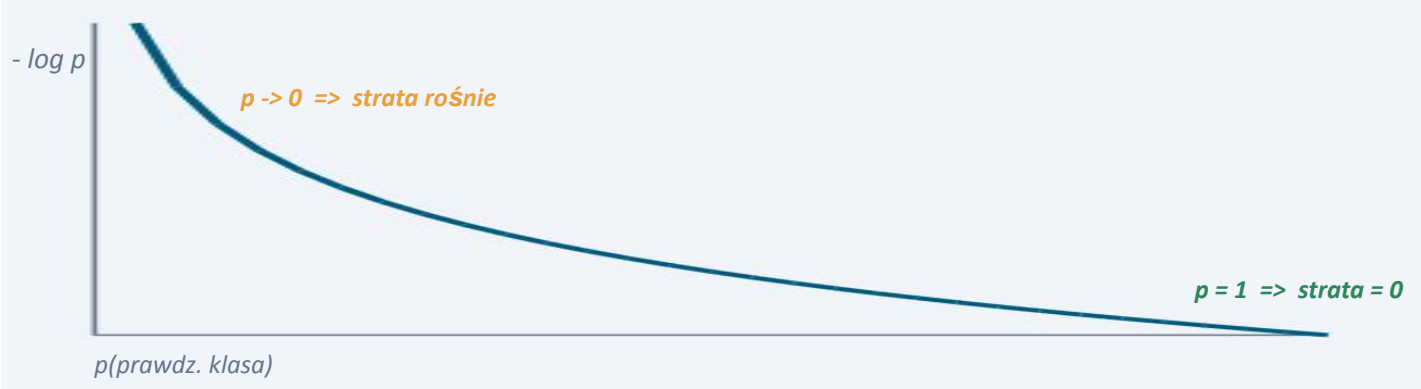
Kształt NLL

```
def objective_function(self, probs: np.ndarray,
true_label: int, perturbations: np.ndarray) -> float:
    probs_for_true_label = probs[:, true_label]
    nll = -np.log(np.clip(probs_for_true_label, 1e-12,
1.0))
    noise_regularization = np.sqrt(np.sum(perturbations
** 2, axis=(1, 2, 3)))
    return nll - self.alpha * noise_regularization
```

Intuicja: dlaczego NLL?

Karze pewność co do prawdziwej klasy, nie tylko błędność

```
def objective_function(self, probs: np.ndarray, true_label: int, perturbations:
np.ndarray) -> float:
    probs_for_true_label = probs[:, true_label]
    nll = -np.log(np.clip(probs_for_true_label, 1e-12, 1.0))
    noise_regularization = np.sqrt(np.sum(perturbations ** 2, axis=(1, 2, 3)))
    return nll - self.alpha * noise_regularization
```



Kształt NLL

Czy krajobraz ataku jest wielomodalny?

SGA-BSR: lokalne przeszukiwanie jako sonda

Faza 1: Stochastyczny wzrost

- Zacznij od delta = 0
- Wybierz losowy piksel
- Zwiększ jego wartość o krok eta
- Zachowaj, jeśli cel nie spada
- Zatrzymaj, gdy klasa się zmienia

Faza 2: Udoskonalanie binarne

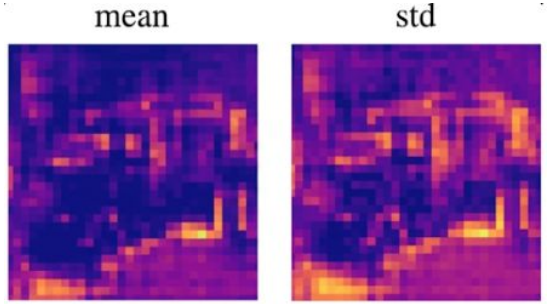
- Dla każdego dotkniętego piksela:
  - binarnie szukaj najmniejszej wartości, która wciąż zmienia klasę
- Wynik: czystsze, mniejsze delta
- Czysto lokalne: utknięcie w minimum pobliskim punktu startowego

Eksperyment: uruchom SGA-BSR 100 razy dla każdego obrazu z różnymi seedami. Czy zawsze lądujemy w tym samym miejscu?

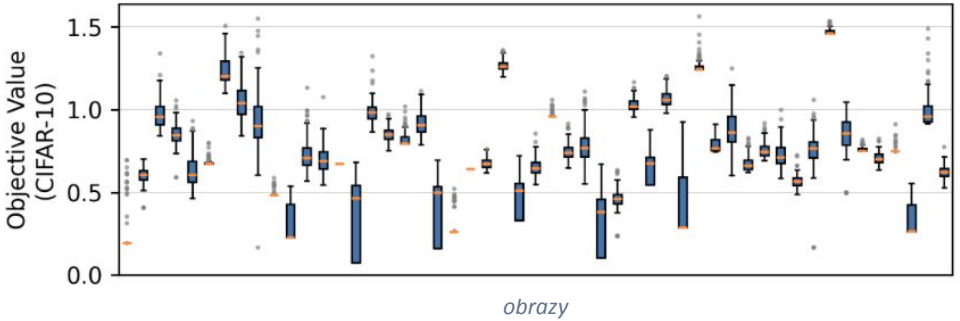
Wyniki SGA-BSR: tak, jest wielomodalny

Różne seedy lądują w różnych minimach lokalnych

Odchyl. std. per piksel w 100 przebiegach



Wartość celu w 100 seedach, per obraz



Wniosek: Ten sam obraz ma wiele różnych skutecznych ataków przy różnych poziomach jakości. Cel BBAA jest wielomodalny, co uzasadnia stosowanie globalnych optymalizatorów.

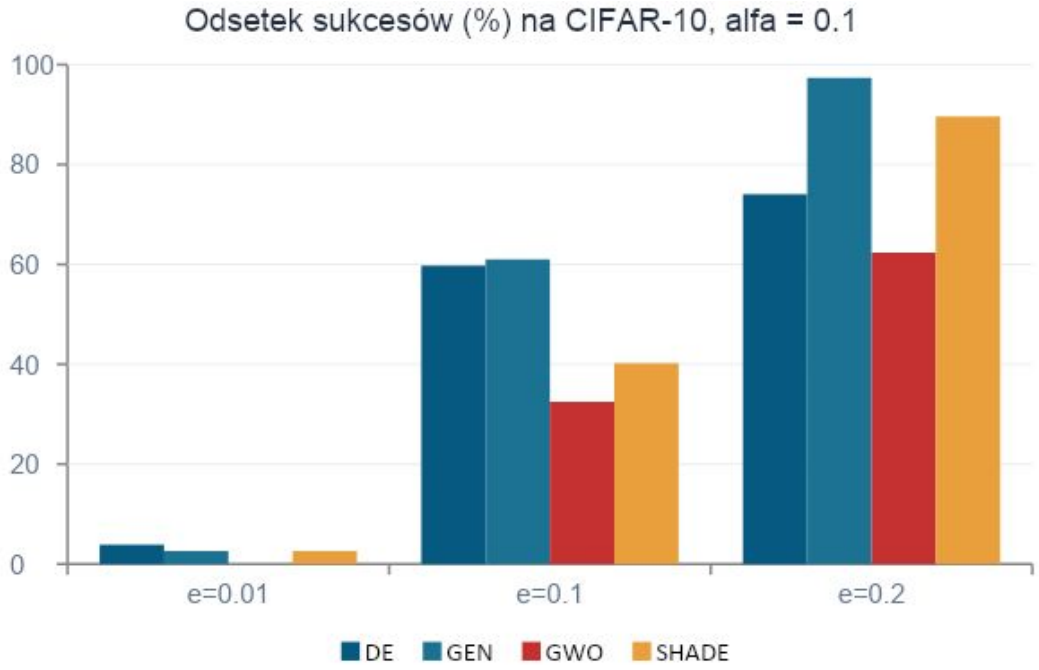
Table 1: Results of adversarial attacks on the CIFAR-10-based classifier

Optim.	α	ε	**Suc. R.** (↑)	**First Succ.** (↓)	L_2	**Obj. fn.** (↑)
DE	0.0	0.01	2.60%	1.0 ± 0.0	0.0071 ± 0.0002	$\mathbf{0.22 \pm 0.26}$
GEN	0.0	0.01	2.60%	1.0 ± 0.0	0.0057 ± 0.0001	0.18 ± 0.23
GWO	0.0	0.01	0.00%	0.0 ± 0.0	0.0000 ± 0.0000	0.19 ± 0.24
INFO	0.0	0.01	1.30%	1.0 ± 0.0	0.0052 ± 0.0000	0.20 ± 0.24
JADE	0.0	0.01	1.30%	1.0 ± 0.0	0.0055 ± 0.0000	0.21 ± 0.26
SADE	0.0	0.01	2.60%	1.0 ± 0.0	0.0062 ± 0.0001	$\underline{0.21 \pm 0.26}$
SHADE	0.0	0.01	2.60%	1.0 ± 0.0	0.0060 ± 0.0005	0.21 ± 0.26
DE	0.0	0.1	28.57%	1.0 ± 0.0	0.0708 ± 0.0044	$\mathbf{0.75 \pm 0.95}$
GEN	0.0	0.1	24.68%	1.0 ± 0.0	0.0565 ± 0.0019	0.41 ± 0.69
GWO	0.0	0.1	1.30%	1.0 ± 0.0	0.0335 ± 0.0000	0.21 ± 0.25
INFO	0.0	0.1	25.97%	1.0 ± 0.0	0.0563 ± 0.0047	0.45 ± 0.66
JADE	0.0	0.1	27.27%	1.0 ± 0.0	0.0614 ± 0.0050	0.60 ± 0.75
SADE	0.0	0.1	28.57%	1.0 ± 0.0	0.0610 ± 0.0043	$\underline{0.63 \pm 0.78}$
SHADE	0.0	0.1	25.97%	1.0 ± 0.0	0.0623 ± 0.0059	0.59 ± 0.73



Wpływ epsilon: budżet zaburzenia

Najważniejszy pojedynczy hiperparametr na CIFAR-10



Na co zwrócić uwagę

- Przy e = 0.01 nikt nic nie zmienia.
- Przy e = 0.1 większość metod zaczyna działać.
- Przy e = 0.2 ranking się rozdziela.
- **Większy budżet = łatwiejszy problem.**

Wpływ epsilon: budżet zaburzenia



(a) original class: sombrero



(b) $\varepsilon = 0.1$: jigsaw puzzle

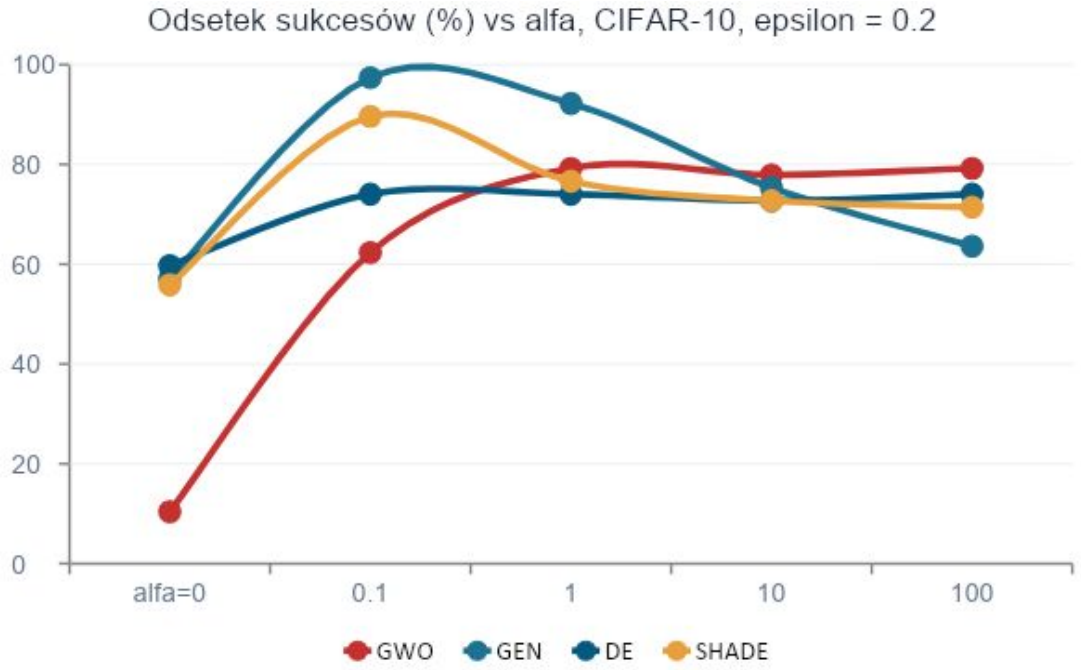


(c) $\varepsilon = 0.2$: jigsaw puzzle

Fig. 4: Example image from ImageNet with two successful attack examples for different ε values

Wpływ alfa: waga regularyzacji

Niemonotoniczny: trochę pomaga, za dużo nie



Wniosek

- **alfa = 0.1 to złoty środek.**
- Zwiększanie do 10 lub 100 nie pomaga dalej.
- GWO jest największym beneficjentem (skok z 10% do 80%).
- *Presja pozostania małym ratuje słabe optymalizatory od rozwiązań narożnych.*

Kto wygrywa i czy wyniki się przenoszą?

GEN i SHADE dominują; ranking stabilny na obu zbiorach danych

Trendy optymalizatorów

GEN, SHADE: wysoki odsetek sukcesów I niska siła zaburzenia

DE, JADE: silne kierunki adwersarialne, większe zaburzenia

INFO: zachowuje się jak zachłanne przeszukiwanie lokalne, szybkie ale niski sufit

DE, GWO: dryfują do narożników obszaru dopuszczalnego bez samo-adaptacji

Przeniesienie na ImageNet

Atak ŁATWIEJSZY na ImageNet przy tych samych (epsilon, alfa)

powód: znacznie więcej wymiarów (~150k vs ~3k) i 1000 klas zamiast 10

Ranking optymalizatorów pozostaje taki sam

GEN i SHADE nadal na szczycie, GWO nadal słabe, INFO efektywne zapytaniowo ale z niskim sufitem

Wnioski i co dalej

Co pokazaliśmy

- Klasyczne zestawy benchmarkowe są małe i nieaktualne względem nowoczesnego ML
- Ataki BBAA są naturalnym, wysokowymiarowym, wielomodalnym benchmarkiem
- Wśród gotowych optymalizatorów, GEN i SHADE są najbardziej niezawodne
- Regularyzacja L2 (umiarkowana alfa) znacząco ułatwia problem

Następne kroki

- Dostrajaj optymalizatory zamiast używać domyślnych parametrów biblioteki
- Ataki ukierunkowane: wymuś konkretną błędną klasę
- Zastąp L2 stratą percepcyjną (LPIPS) dla lepszego dopasowania do ludzkiego widzenia
- Rozszerzenie na ochronę przed złośliwą edycją dyfuzyjną
- Więcej klasyfikatorów, więcej zbiorów danych

Dziękuję! Pytania?